



MAKİNE ÖĞRENMESİ YÖNTEMLERİ KULLANILARAK HAVAYOLU YOLCU MEMNUNİYETİNİN SINIFLANDIRILMASI

Tuğba Nur ASLAN

210101030

Makine Öğrenmesi Yöntemleri Kullanılarak Havayolu Yolcu Memnuniyetinin Sınıflandırılması

Tuğba Nur ASLAN^{1,*}

¹Yalova Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü, 77100, YALOVA

Öz

Makale Bilgisi

Başvuru: 07/05/2026

Anahtar Kelimeler

Havayolu yolcu memnuniyeti, Makine öğrenmesi, Sınıflandırma, Öznitelik seçimi, SHAP, XGBoost

Havayolu taşımacılığında yolcu memnuniyeti hem müşteri sadakati hem de rekabet avantajı açısından belirleyici bir etkidir. Bu çalışmada, Kaggle platformunda açık erişimli olarak sunulan ve 129.880 yolcuya ait anket yanıtlarından oluşan veri seti kullanılarak yolcu memnuniyetinin makine öğrenmesi yöntemleriyle sınıflandırılması amaçlanmıştır. Veri ön işleme aşamasında eksik değerler medyan ile doldurulmuş, kategorik değişkenler One-Hot Encoding ile sayısallaştırılmış ve hedef değişken ikili sınıflandırma yapısına uygun biçimde kodlanmıştır. Modelleme aşamasında k-En Yakın Komşu (kNN), Naive Bayes, Lineer Destek Vektör Makineleri (LSVM), RBF çekirdekli Destek Vektör Makineleri (RBF SVM), Lojistik Regresyon, Random Forest, XGBoost ve Çok Katmanlı Algılayıcı (MLP) olmak üzere sekiz farklı algoritma 5 katlı çapraz doğrulama ile karşılaştırılmıştır. Çalışmanın özgün katkısı olarak, literatürde bu veri seti üzerinde yalnızca açıklanabilirlik amacıyla kullanılan SHAP (SHapley Additive exPlanations) değerleri ilk kez bir öznitelik seçim mekanizması olarak uygulanmış; XGBoost ve Random Forest modellerinden elde edilen normalize SHAP skorları birleştirilerek model-agnostik bir öznitelik sıralaması oluşturulmuştur. Elde edilen bulgular, doğrusal modellerin bu problemde görece sınırlı kaldığını, ağaç tabanlı topluluk yöntemlerinin ise belirgin biçimde öne çıktığını ortaya koymuştur. XGBoost ve Random Forest, bağımsız test kümesinde yaklaşık %96,34 doğrulukla en yüksek başarıyı sergilemiş; SHAP tabanlı öznitelik seçimi ise rekabetçi başarımlar düzeylerini koruyarak öznitelik sayısını anlamlı ölçüde azaltabildiğini göstermiştir. Bu yönüyle çalışma, havayolu yolcu memnuniyeti tahminine ilişkin literatüre hem karşılaştırmalı hem de metodolojik açıdan özgün bir katkı sunmaktadır.

Classification of Airline Passenger Satisfaction Using Machine Learning Methods

Abstract

Keywords

Airline passenger satisfaction, Machine learning, Classification, Feature selection, SHAP, XGBoost

Passenger satisfaction in air transportation is a decisive factor for both customer loyalty and competitive advantage. In this study, an open-access dataset published on Kaggle, comprising survey responses from 129,880 passengers, was used to classify passenger satisfaction with machine learning methods. During preprocessing, missing values were imputed using the median, categorical variables were transformed via One-Hot Encoding, and the target variable was recoded to fit a binary classification setting. Eight different algorithms—k-Nearest Neighbors (kNN), Naive Bayes, Linear Support Vector Machines (LSVM), RBF-kernel Support Vector Machines (RBF SVM), Logistic Regression, Random Forest, XGBoost, and Multilayer Perceptron (MLP)—were then compared under identical conditions using 5-fold stratified cross-validation. As the original contribution of this work, SHAP (SHapley Additive exPlanations) values, which have so far been applied to this dataset only for explainability purposes, were used for the first time as a feature selection mechanism; normalized SHAP scores obtained from XGBoost and Random Forest were combined to produce a model-agnostic feature ranking. The findings indicate that linear models perform relatively poorly on this problem, whereas tree-based ensemble methods clearly stand out. XGBoost and Random Forest achieved the highest performance on the independent test set, reaching approximately 96.34% accuracy, and the proposed SHAP-based feature selection meaningfully reduced the number of features while preserving competitive performance. In this respect, the study offers both a comparative and a methodologically novel contribution to the literature on airline passenger satisfaction prediction.

1. GİRİŞ (INTRODUCTION)

Günümüzde hizmet sektörü, müşteri deneyimini ölçmek ve iyileştirmek için veri odaklı yaklaşımlara giderek daha fazla kullanılmaktadır. Havayolu taşımacılığı da milyonlarca insanın tercih ettiği ve rekabetin yoğun biçimde yaşandığı en temel hizmet sektörlerinden biridir. Yolcular artık yalnızca uçuş saati veya bilet fiyatıyla değil; koltuk konforu, uçuş içi wifi, online check-in kolaylığı gibi hizmet boyutlarını da göz önünde bulundurarak havayolu tercihlerini yapmaktadır [1]. Bu nedenle havayolu şirketleri için yolcu memnuniyetini

anlamak ve öngörmek hem rekabet avantajı sağlama hem de marka sadakati açısından kritik bir konu haline gelmiştir.

Geleneksel yöntemlerde memnuniyet, anketler veya manuel geri bildirim süreçleriyle ölçülmekte; bu yaklaşımlar zaman alıcı olmakla birlikte yalnızca küçük örneklemelerle sınırlı kalmaktadır. Son yıllarda veri bilimi ve makine öğrenmesi alanındaki gelişmeler, hizmet sektörüne ait büyük ölçekli müşteri verilerinden otomatik tahmin modelleri geliştirilmesini mümkün kılmış; hiperparametre optimizasyonu ve öznelik seçimi gibi tekniklerle bu modellerin başarımı daha da artırılabilir hale gelmiştir [2]. Özellikle sınıflandırma algoritmaları, yüksek boyutlu veri setlerinden anlamlı örüntüler çıkarma, değişkenler arasındaki ilişkileri belirleme ve bu ilişkileri yorumlayarak müşteri davranışlarına yönelik tahminlerde bulunma konusunda etkili biçimde kullanılmaktadır.

Literatürde bu konuya yönelik pek çok çalışma mevcuttur. [3]'te on farklı makine öğrenmesi algoritması karşılaştırılmış; Deep Learning %95,42 doğrulukla en yüksek başarıyı sergilerken Random Forest %94,41 ile ikinci sıraya yerleşmiştir. [4]'te ise rastgele ormana dayalı öznelik seçimi (RF-RFE) ve lojistik regresyonu birleştiren hibrit bir yaklaşımla 22 öznelikten 17'si seçilerek başarımların artışı elde edilmiştir. [5]'te online boarding, uçuş içi eğlence ve koltuk konforu gibi hizmet boyutlarının memnuniyetle en güçlü ilişkiyi gösteren değişkenler olduğu raporlanmıştır. [6]'da ise Adam optimizasyonu ile eğitilmiş derin sinir ağı kullanılarak aynı veri seti üzerinde %99,3 doğruluk elde edilmiş ve literatürdeki en yüksek sonuç olarak bildirilmiştir. Bununla birlikte, incelenen çalışmaların önemli bir bölümü yalnızca model performanslarının karşılaştırılmasına odaklanmakta; öznelik seçimi sürecinde kullanılan yöntemler ise çoğunlukla geleneksel istatistiksel teknikler veya wrapper tabanlı yaklaşımlarla sınırlı kalmaktadır [3, 4].

Bu çalışmada, 129.880 yolcuya ait gözlem içeren açık erişimli bir havayolu memnuniyet veri seti [7] kullanılmıştır. Veri ön işleme aşamasında gereksiz sütunlar çıkarılmış, eksik değerler medyan ile doldurulmuş, kategorik değişkenler One-Hot Encoding ile sayısallaştırılmış ve sayısal değişkenler StandardScaler ile ölçeklendirilmiştir. Ardından kNN, Naive Bayes, Lineer SVM, RBF SVM, Lojistik Regresyon, Random Forest, XGBoost ve MLP olmak üzere sekiz farklı sınıflandırma algoritması uygulanmış; tüm modellerin başarımları 5 katlı katmanlı çapraz doğrulama ile değerlendirilerek doğruluk, kesinlik, duyarlılık, F1 skoru, özgüllük ve MCC metrikleri üzerinden raporlanmıştır.

Çalışmanın özgün katkısı, öznelik seçimi adımıyla SHAP (SHapley Additive exPlanations) değerlerinin kullanılmasıdır. SHAP, oyun teorisindeki Shapley değerlerine dayanan ve her bir özneliğin model çıktısına olan katkısını matematiksel olarak nicelleştiren bir yöntemdir [10]. Literatürde bu veri seti üzerinde SHAP, açıklanabilirlik ve öznelik önemini görselleştirme amacıyla kullanılmış [5]; ancak doğrudan bir öznelik seçim mekanizması olarak değerlendirilmemiştir. Bu çalışmada XGBoost ve Random Forest modellerinden elde edilen normalize SHAP skorları birleştirilerek model-agnostik bir öznelik sıralaması oluşturulmuş ve kümülatif %90 önem eşiği kullanılarak 22 öznelikten 14'ü seçilmiştir.

2. YÖNTEMLER (METHODS)

2.1. Veri Seti (Data Set)

Bu çalışmada, Kaggle platformunda açık erişimli olarak yayımlanan Airline Passenger Satisfaction veri seti [7] kullanılmıştır. Veri seti, havayolu yolcularıyla yapılan memnuniyet anketlerinden derlenmiş olup yolcuların demografik özellikleri, seyahat türü ve uçuş sınıfı bilgilerinin yanı sıra uçuş deneyimine ilişkin çeşitli hizmet değerlendirmelerini de kapsamaktadır. Uçuş içi kablosuz internet hizmeti, online rezervasyon kolaylığı, kapı konumu, yiyecek-içecek hizmeti, online boarding, koltuk konforu, uçuş içi eğlence, kabin hizmetleri, bagaj işlemleri, temizlik ve gecikme süreleri gibi yolcu memnuniyetini etkileyebilecek pek çok değişken veri setinde yer almakta; bu da memnuniyet üzerinde rol oynayan faktörlerin geniş bir çerçevede ele alınmasına imkân tanımaktadır.

Veri seti Kaggle üzerinde eğitim ve test olmak üzere iki ayrı dosya halinde sunulmaktadır. Eğitim kümesi 103.904, test kümesi ise 25.976 kayıttan oluşmakta ve böylece toplam gözlem sayısı 129.880'e ulaşmaktadır. Bu çalışmada eğitim kümesi model geliştirme ve karşılaştırma sürecinde kullanılmış, test kümesi ise modellerin nihai başarımını bağımsız biçimde değerlendirebilmek amacıyla ayrı tutulmuştur. Eğitim kümesi

üzerinde ayrıca 5 katlı katmanlı çapraz doğrulama uygulanmıştır. Ham veride toplam 25 sütun bulunmakta olup bunların arasında kimlik ve sıra bilgisi taşıyan yardımcı sütunların yanı sıra yolcu özelliklerini ve hizmet kalitesini temsil eden öznitelikler yer almaktadır.

Veri setindeki hedef değişken *satisfaction* sütunudur ve bu değişken yolcu memnuniyetini "neutral or dissatisfied" ve "satisfied" olmak üzere iki sınıf altında ifade etmektedir. Eğitim kümesinde 45.025 yolcu (%43,33) memnun, 58.879 yolcu (%56,67) ise memnun olmayan veya nötr olarak etiketlenmiştir. Sınıflar arasındaki bu fark, veri setinin tam dengeli olmadığını göstermektedir. Bu nedenle modellerin değerlendirilmesinde yalnızca doğruluk değerine bakmak yanıltıcı olabilmekte; sınıf dengesizliğine daha duyarlı olan F1 skoru, özgüllük ve Matthews Korelasyon Katsayısı (MCC) gibi metriklerin de göz önünde bulundurulması önem kazanmaktadır.

Veri seti hem kategorik hem de sayısal değişkenleri bir arada barındırması nedeniyle havayolu yolcu memnuniyetinin sınıflandırılması problemi için uygun bir yapı sunmaktadır. Geniş örneklem büyüklüğü ise farklı makine öğrenmesi algoritmalarının karşılaştırmalı olarak değerlendirilmesine olanak tanımaktadır. Veri setine ait öznitelikler ve kısa açıklamaları Tablo 1'de verilmiştir.

Tablo 1. Eğitim veri setindeki öznitelikler ve açıklamaları

Öznitelik	Açıklama
Unnamed: 0	Veri setindeki satır sırasını tutan indeks sütunu.
id	Her yolcu kaydı için benzersiz kimlik değeri.
Gender	Yolcunun cinsiyeti.
Customer Type	Yolcunun müşteri tipi; sadık müşteri veya sadakatsiz müşteri bilgisi.
Age	Yolcunun yaşı.
Type of Travel	Seyahat türü; iş seyahati veya kişisel seyahat bilgisi.
Class	Uçuş sınıfı; Business, Eco veya Eco Plus.
Flight Distance	Uçuş mesafesi.
Inflight wifi service	Yolcunun uçuş içi kablosuz internet hizmetine ilişkin değerlendirmesi.
Departure/Arrival time convenient	Kalkış ve varış saatlerinin uygunluğuna ilişkin değerlendirme.
Ease of Online booking	Çevrim içi rezervasyon işleminin kolaylığına ilişkin değerlendirme.
Gate location	Kapı konumunun uygunluğuna ilişkin değerlendirme.
Food and drink	Yiyecek ve içecek hizmetlerine ilişkin değerlendirme.
Online boarding	Çevrim içi uçağa biniş sürecine ilişkin değerlendirme.
Seat comfort	Koltuk konforuna ilişkin değerlendirme.
Inflight entertainment	Uçuş içi eğlence hizmetlerine ilişkin değerlendirme.
On-board service	Uçak içi genel hizmet kalitesine ilişkin değerlendirme.
Leg room service	Bacak mesafesi ve ilgili hizmete ilişkin değerlendirme.
Baggage handling	Bagaj işlemlerine ilişkin değerlendirme.
Checkin service	Check-in hizmetine ilişkin değerlendirme.
Inflight service	Uçuş içi hizmet kalitesine ilişkin değerlendirme.
Cleanliness	Temizlik düzeyine ilişkin değerlendirme.

Öznitelik	Açıklama
Departure Delay in Minutes	Kalkış gecikme süresi (dakika).
Arrival Delay in Minutes	Varış gecikme süresi (dakika).
satisfaction	Hedef değişken; yolcunun memnuniyet durumu (neutral or dissatisfied / satisfied).

2.2. Veri Ön İşleme (Data Preprocessing)

Modelleme aşamasına geçmeden önce veri seti üzerinde bir dizi ön işleme adımı uygulanmıştır. Bu sürecin temel amacı; ham veriyi makine öğrenmesi algoritmalarına uygun hâle getirmek, veri kalitesini artırmak ve model başarımını olumsuz etkileyebilecek sorunları en aza indirmektir. Bu kapsamda gereksiz sütunların kaldırılması, eksik değerlerin giderilmesi, hedef değişkenin sayısal forma dönüştürülmesi, bağımsız ve bağımlı değişkenlerin ayrıştırılması ve öznitelik türlerinin belirlenmesi işlemleri sırasıyla gerçekleştirilmiştir. Ham veri yapısında sınıflandırma açısından doğrudan bilgi taşımayan bazı sütunlar bulunmaktadır. *Unnamed: 0* sütunu veri dosyasındaki sıra bilgisini, *id* sütunu ise yolcu kimlik numarasını temsil etmektedir. Bu değişkenlerin yolcu memnuniyetinin tahmin edilmesine herhangi bir katkı sağlamayacağı açıktır; bu nedenle her iki sütun da analiz kapsamı dışında bırakılmıştır.

Veri setinde eksik değer içeren tek sütun *Arrival Delay in Minutes* değişkenidir. Bu sütundaki eksik gözlemler, veri dağılımını mümkün olduğunca korumak amacıyla medyan değer kullanılarak doldurulmuştur. Medyanın tercih edilmesinin temel nedeni, uç değerlerden aritmetik ortalamaya kıyasla çok daha az etkilenmesi ve gecikme süresi gibi çarpık dağılım gösteren değişkenlerde daha dengeli bir temsil sağlamasıdır.

Hedef değişken olan *satisfaction* sütunu veri kümesinde metinsel biçimde yer almakta ve iki sınıftan oluşmaktadır: "neutral or dissatisfied" ve "satisfied". Makine öğrenmesi algoritmalarında kullanılabilmesi için bu sınıflar sayısal forma dönüştürülmüş; "neutral or dissatisfied" 0, "satisfied" ise 1 olarak kodlanmıştır. Böylece problem ikili sınıflandırma yapısına uygun hâle getirilmiştir.

Veri temizleme ve hedef değişkenin kodlanmasının ardından veri seti bağımsız ve bağımlı değişkenler olarak ikiye ayrılmıştır. *Satisfaction* sütunu hedef değişken (y) olarak belirlenmiş, bu sütun dışındaki tüm öznitelikler ise giriş değişkenleri (X) kümesini oluşturmuştur. Bu aşamada *Unnamed: 0* ve *id* sütunları çıkarıldıktan sonra modelleme sürecine 22 öznitelik dahil edilmiştir.

Veri setindeki öznitelikler, türlerine göre kategorik ve sayısal olmak üzere iki gruba ayrılmıştır. *Gender*, *Customer Type*, *Type of Travel* ve *Class* nesne/string türündeki kategorik sütunlardan; geri kalan değişkenler ise sayısal sütunlardan oluşmaktadır. Bu ayırım, ilerleyen aşamalarda uygulanacak kodlama ve ölçeklendirme işlemlerinin doğru biçimde yürütülmesi açısından önemlidir; çünkü kategorik ve sayısal değişkenler farklı ön işleme teknikleri gerektirmektedir. Kategorik değişkenler One-Hot Encoding ile sayısallaştırılmış, sayısal değişkenler ise *StandardScaler* kullanılarak ortalaması sıfır ve standart sapması bir olacak şekilde ölçeklendirilmiştir. Bu standardizasyon, özellikle uzaklık tabanlı yöntemlerde (kNN, SVM gibi) ve doğrusal modellerde değişkenlerin model üzerindeki etkisini dengelemek açısından önemli bir adımdır.

Bu ön işleme adımlarının ardından elde edilen veri seti hem baseline modellerin doğrudan kullanımına hem de bir sonraki bölümde anlatılan SHAP tabanlı öznitelik seçimi sürecine girdi olarak kullanılmıştır.

2.3. SHAP Tabanlı Öznitelik Seçimi (SHAP-Based Feature Selection)

Makine öğrenmesi modellerinde tüm özniteliklerin kullanılması her zaman en iyi sonucu vermeyebilir. Bazı değişkenler model çıktısına çok az katkı sağlarken, bazıları gereksiz bilgi ekleyerek modelin genelleme kapasitesini olumsuz etkileyebilir. Öznitelik seçimi, bu sorunlara yönelik geliştirilmiş bir yaklaşımdır ve modelin başarımını korurken karmaşıklığını azaltmayı hedefler [8].

Bu çalışmada, geleneksel öznitelik seçim yöntemlerinden farklı olarak SHAP değerleri bir öznitelik seçim mekanizması olarak kullanılmıştır. Lundberg ve Lee tarafından önerilen SHAP yöntemi, oyun teorisindeki Shapley değerlerine dayanmakta ve her bir özneliğin model çıktısına olan katkısını matematiksel garantilerle nicelleştirmektedir [10]. SHAP, model türünden bağımsız (model-agnostik) çalışabilmesi ve tutarlı bir önem ölçütü sunabilmesi nedeniyle açıklanabilirlik literatüründe yaygın biçimde kullanılmaktadır. Bu veri setine ilişkin önceki çalışmalarda SHAP yalnızca açıklanabilirlik amacıyla ele alınmış; öznitelik seçim süreçlerinde doğrudan kullanılmamıştır [5].

Bu çalışmada SHAP değerleri, doğrusal olmayan ilişkileri etkili biçimde modelleyebilen XGBoost ve Random Forest algoritmalarına uygulanmıştır. Her iki model için TreeExplainer aracılığıyla hesaplanan SHAP değerleri, hesaplama maliyetini sınırlamak amacıyla eğitim verisinden rastgele seçilen 2.000 gözlem üzerinden elde edilmiştir. Her öznitelik için mutlak SHAP değerlerinin ortalaması alınarak global önem skorları hesaplanmış; ardından iki modelden gelen skorlar L1 normuna göre normalize edilerek ortalamaları alınmıştır. Bu birleşik yaklaşım, tek bir algoritmanın olası önyargılarına bağlı kalmadan daha kararlı bir öznitelik önemi tahmini sağlamıştır. One-Hot Encoding sonucu birden fazla alt sütuna ayrılan kategorik değişkenler için ise alt sütunlara ait SHAP skorları toplanarak orijinal değişkenin tek bir önem skoru elde edilmiştir.

Öznitelikler birleşik önem skoruna göre büyükten küçüğe sıralanmış ve kümülatif olarak toplam önemin %90'ını açıklayan öznitelikler seçilmiştir. %90 eşiği, model başarımının korunması ile öznitelik sayısının azaltılması arasında dengeli bir tercih sunması nedeniyle benimsenmiştir. Bu süreç sonunda 22 özneliğin 14'ü modelleme sürecine dahil edilecek şekilde seçilmiş, geri kalan 8 öznitelik ise model dışında bırakılmıştır. Seçilen öznitelikler ve kümülatif önem skorları Tablo 2'de sunulmaktadır.

Tablo 2. SHAP tabanlı öznitelik seçimi sonucunda belirlenen öznitelikler ve kümülatif önem skorları

Sıra	Öznitelik	Kümülatif Önem (%)
1	Inflight wifi service	19,37
2	Type of Travel	37,77
3	Online boarding	48,98
4	Customer Type	57,79
5	Class	65,01
6	Inflight entertainment	68,55
7	Baggage handling	71,83
8	Seat comfort	74,81
9	Inflight service	77,77
10	Checkin service	80,64
11	Leg room service	83,34
12	Ease of Online booking	85,70
13	Cleanliness	87,94
14	On-board service	90,15

Tablo 2 incelendiğinde, en yüksek öneme sahip özneliğin *Inflight wifi service* olduğu görülmektedir; bu öznitelik tek başına toplam önemin yaklaşık beşte birini açıklamaktadır. Bunu *Type of Travel*, *Online boarding* ve *Customer Type* gibi yolcunun seyahat profilini ve hizmet deneyimini doğrudan yansıtan

değişkenler izlemektedir. Bu sıralama, [5] numaralı çalışmada raporlanan online boarding ve uçuş içi eğlence gibi hizmet boyutlarının memnuniyetle güçlü ilişki gösterdiği bulgusuyla büyük ölçüde örtüşmektedir.

Modelleme sürecinin dışında bırakılan 8 öznitelik *Gender, Age, Flight Distance, Departure/Arrival time convenient, Gate location, Food and drink, Departure Delay in Minutes ve Arrival Delay in Minutes* değişkenlerinden oluşmaktadır. İlginç biçimde, gecikme süreleri gibi sezgisel olarak memnuniyeti olumsuz etkileyebileceği düşünülen değişkenlerin SHAP analizinde görece düşük katkı sağladığı görülmüştür. Bu durum, gecikme bilgisinin diğer değişkenler üzerinden dolaylı olarak modele yansımış olabileceğine ya da bu veri setinde gecikmenin tek başına memnuniyeti açıklamada belirleyici olmadığına işaret etmektedir.

2.4. Sınıflandırma Yöntemleri (Classification Methods)

Veri seti Kaggle platformunda eğitim ve test olmak üzere iki ayrı dosya halinde sunulmaktadır. Bu çalışmada eğitim kümesi model geliştirme sürecinde kullanılmış, test kümesi ise modellerin nihai başarımının bağımsız biçimde değerlendirilebilmesi amacıyla ayrı tutulmuştur. Modellerin karşılaştırılmasında eğitim kümesi üzerinde 5 katlı katmanlı çapraz doğrulama uygulanmıştır. Bu yöntemde eğitim verisi beş alt kümeye ayrılmış; her iterasyonda dört alt küme eğitim, bir alt küme ise doğrulama amacıyla kullanılmıştır. İşlem beş kez tekrarlanmış ve her alt küme bir kez doğrulama verisi olarak değerlendirilmiştir.

Modeller arasında adil bir karşılaştırma sağlamak ve veri sızıntısını (data leakage) önlemek amacıyla tüm modeller birleşik bir makine öğrenmesi hattı içinde uygulanmıştır. Sayısal değişkenler StandardScaler ile standardize edilmiş, kategorik değişkenler ise One-Hot Encoding yöntemiyle sayısallaştırılmış; dönüşüm sırasında bilinmeyen kategoriler göz ardı edilmiştir. 5 katlı katmanlı çapraz doğrulama sürecinde tüm ön işleme dönüşümleri yalnızca her foldun eğitim kısmı üzerinde fit edilmiş ve ardından doğrulama kısmına uygulanmıştır. Böylece doğrulama verisinden ön işleme veya eğitim aşamalarına herhangi bir bilgi sızması engellenmiştir. Aynı ön işleme çerçevesi tüm sınıflandırma modelleri için kullanılmıştır.

Deneylerde kullanılan temel parametre ayarları Tablo 3'te özetlenmiştir. Açıkça belirtilmeyen parametreler, ilgili kütüphanelerin varsayılan değerlerinde bırakılmıştır.

Tablo 3. Sınıflandırma modellerinin temel parametre ayarları

Model	Uygulama	Temel parametre ayarları
kNN	KNeighborsClassifier	n_neighbors = 5
Naive Bayes	GaussianNB	Default parameters
Lojistik Regresyon	LogisticRegression	max_iter = 1000, random_state = 42
LSVM	LinearSVC	max_iter = 5000, random_state = 42
RBF SVM	SVC	kernel = 'rbf'
Random Forest	RandomForestClassifier	n_estimators = 100, random_state = 42, n_jobs = -1
MLP	MLPClassifier	hidden_layer_sizes = (100,), max_iter = 300, random_state = 42
XGBoost	XGBClassifier	n_estimators = 100, random_state = 42, eval_metric = 'logloss', verbosity = 0, n_jobs = -1

Çalışmada değerlendirilen sekiz algoritma, çalışma prensipleri bakımından farklı yaklaşımları temsil ettikleri için seçilmiştir. Bu sayede doğrusal modellerden topluluk yöntemlerine, olasılıksal yaklaşımlardan yapay sinir ağlarına kadar geniş bir yelpazede karşılaştırma yapılabilmektedir. Tüm modeller, yolcuları "memnun" ve "memnun değil / kararsız" olarak iki sınıfa ayırmak üzere ikili sınıflandırma kurgusunda eğitilmiştir.

2.4.1. k-Nearest Neighbors (kNN)

kNN, sınıfı bilinmeyen bir gözlemi eğitim kümesindeki en yakın k komşusunun çoğunluk sınıfına atayan, parametrik olmayan bir sınıflandırma yöntemidir [8]. Yakınlık ölçütü olarak yaygın biçimde Öklid uzaklığı kullanılır; n öznitelik boyutunda iki gözlem arasındaki uzaklık şu şekilde tanımlanır:

$$d(x, x_i) = \sqrt{\sum_{j=1}^n (x_j - x_{ij})^2}$$

Yöntem ölçeğe duyarlı olduğundan bu çalışmada sayısal değişkenler önceden standartlaştırılmıştır. k parametresi küçük seçildiğinde aşırı öğrenme, büyük seçildiğinde ise aşırı genelleme riski doğmaktadır. Bu nedenle model karşılaştırması kapsamında varsayılan $k = 5$ değeri tercih edilmiştir.

2.4.2. Naive Bayes

Naive Bayes, Bayes Teoremi'ne dayanan olasılıksal bir sınıflandırma yöntemidir. Bu yöntemde, özniteliklerin sınıfa koşullu olarak birbirinden bağımsız olduğu varsayılır; bu güçlü bağımsızlık kabulü nedeniyle yöntem "naive" olarak adlandırılmaktadır [8]. Bir X gözleminin C_k sınıfına ait sonsal olasılığı aşağıdaki gibi ifade edilir [8]:

$$P(Y = C_k | X) = \frac{P(Y = C_k) P(X | Y = C_k)}{P(X)}$$

Sınıflandırma işlemi, bu olasılığı en büyük yapan C_k sınıfının seçilmesiyle gerçekleştirilir. Bu çalışmada, veri setinde sürekli sayısal değişkenlerin bulunması nedeniyle bu çalışmada Gaussian Naive Bayes yaklaşımı kullanılmıştır. Bu yöntemde her özneliğin sınıf koşullu olasılığı, normal dağılım varsayımı altında hesaplanmaktadır [8]:

$$P(x_i | Y = C_k) = \frac{1}{\sigma_{ik} \sqrt{2\pi}} e^{-\frac{(x_i - \mu_{ik})^2}{2\sigma_{ik}^2}}$$

Naive Bayes; düşük hesaplama maliyeti, hızlı uygulanabilirliği ve diğer modellerin başarımını ölçmek için doğal bir alt sınır oluşturması nedeniyle çalışmada temel karşılaştırma modellerinden biri olarak değerlendirilmiştir.

2.4.3. Destek Vektör Makineleri (SVM)

Destek Vektör Makineleri (DVM), gözetimli öğrenme yöntemleri arasında yer alan ve sınıfları birbirinden ayıran en uygun karar sınırını belirlemeyi amaçlayan bir sınıflandırma yöntemidir [8]. Yöntemin temel hedefi, iki sınıf arasında mümkün olan en geniş marjı sağlayan hiper düzlemi bulmaktır. Karar sınırına en yakın örnekler destek vektörleri olarak adlandırılır ve modelin oluşumunda kritik rol oynar [8]. İki sınıfı ayıran hiper düzlem aşağıdaki gibi ifade edilmektedir [8]:

$$w^T x + b = 0$$

Burada w ağırlık vektörünü, b ise sabit terimi göstermektedir.

Çalışmada hem Doğrusal Destek Vektör Makineleri (LSVM) hem de RBF çekirdekli Destek Vektör Makineleri (RBF SVM) uygulanmıştır. LSVM, doğrusal bir karar sınırının yeterli olduğu durumlarda kullanılan ve yüksek boyutlu veri kümelerinde hesaplama açısından verimli sonuçlar sunan bir yöntemdir.

RBF SVM ise çekirdek fonksiyonu yardımıyla doğrusal olmayan ilişkileri modelleyebilmekte ve daha karmaşık karar sınırları oluşturabilmektedir. Bu iki varyantın birlikte kullanılması, doğrusal ve doğrusal olmayan yaklaşımların aynı veri seti üzerinde karşılaştırılmasına imkân tanımıştır.

2.4.4. Lojistik Regresyon

Lojistik regresyon, ikili sınıflandırma problemlerinde yaygın olarak kullanılan olasılık temelli bir yöntemdir [8]. Bu yöntem, bir gözlemin belirli bir sınıfa ait olma olasılığını tahmin etmek için sigmoid fonksiyonundan yararlanır. Elde edilen çıktı 0 ile 1 arasında bir olasılık değeri olup, belirli bir eşik değere göre sınıf kararı verilmektedir [8].

Lojistik regresyon modeli aşağıdaki gibi ifade edilmektedir [8]:

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}}$$

Burada p , gözlemin pozitif sınıfa ait olma olasılığını; β_0 sabit terimi; $\beta_1, \beta_2, \dots, \beta_n$ ise bağımsız değişken katsayılarını göstermektedir. Lojistik regresyon, yorumlanabilir yapısı ve katsayılar üzerinden değişkenlerin etkisini doğrudan değerlendirme imkânı sunması nedeniyle çalışmada doğrusal yaklaşımların temel temsilcisi olarak yer almıştır.

2.4.5. Random Forest

Random Forest, birden fazla karar ağacının bir arada kullanıldığı topluluk öğrenme yöntemlerinden biridir [8]. Her ağaç, eğitim verisinin rastgele örneklenmiş bir alt kümesi ve rastgele seçilen öznelikler üzerinde bağımsız olarak eğitilir; nihai sınıf tahmini ise tüm ağaçların çoğunluk oylamasıyla belirlenir:

$$\hat{y} = \text{mode} \{ h_1(x), h_2(x), \dots, h_n(x) \}$$

Burada $h_i(x)$, i . ağacın ürettiği sınıf tahminini göstermektedir. Bu yapı, tek bir karar ağacına kıyasla aşırı öğrenme riskini önemli ölçüde azaltmakta ve daha kararlı sonuçlar üretmektedir [8]. Hizmet kalitesi değerlendirmeleri ve gecikme bilgileri gibi birbiriyle ilişkili çok sayıda değişken içeren havayolu memnuniyet veri kümesi, Random Forest'in güçlü olduğu bir kullanım senaryosuna karşılık gelmektedir.

2.4.6. XGBoost

XGBoost (Extreme Gradient Boosting), karar ağaçlarını art arda oluşturarak hataları kademeli biçimde azaltmaya çalışan bir topluluk öğrenme yöntemidir [8]. Her yeni ağaç, önceki ağaçların yanlış sınıflandırdığı örnekleri daha iyi öğrenmeye çalışır; bu sayede model, zayıf öğrenicilerin birleşimiyle güçlü bir sınıflandırıcıya dönüşür. XGBoost; yüksek tahmin başarımı, düzenlileştirme mekanizmaları ve büyük veri kümelerinde verimli çalışabilmesi sayesinde son yıllarda yaygın biçimde tercih edilen yöntemlerden biri haline gelmiştir [8].

XGBoost modelinde tahmin çıktısı genel olarak aşağıdaki gibi ifade edilebilir [8]:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i)$$

Burada $\hat{y}_i$, i . gözlem için tahmin edilen çıktıyı, f_k ise her bir karar ağacını temsil etmektedir. Nihai tahmin, tüm ağaçların katkılarının toplanmasıyla elde edilir. Yöntemin değişkenler arasındaki karmaşık etkileşimleri öğrenebilme yeteneği, hizmet kalitesi puanları, seyahat türü ve gecikme bilgileri gibi farklı türde özneliklerin bir arada bulunduğu bu veri seti için onu güçlü bir aday haline getirmektedir.

2.4.7. Çok Katmanlı Algılayıcı (MLP)

Çok Katmanlı Algılayıcı (MLP), yapay sinir ağları ailesine ait bir sınıflandırma yöntemidir. Model; girdi katmanı, bir veya daha fazla gizli katman ve çıktı katmanından oluşmaktadır. Katmanlardaki nöronlar, aktivasyon fonksiyonları aracılığıyla veriler arasındaki ilişkileri öğrenmekte; modelin ağırlıkları ise geri yayılım (backpropagation) yöntemiyle güncellenmektedir. Bu yapı sayesinde MLP, doğrusal olmayan ve karmaşık örüntüleri öğrenebilmektedir.

MLP'de bir nöronun çıktısı genel olarak aşağıdaki gibi ifade edilebilir [9]:

$$y = f \left(\sum_{i=1}^n w_i x_i + b \right)$$

Burada x_i giriş değerlerini, w_i ağırlıkları, b sabit terimi ve f ise aktivasyon fonksiyonunu göstermektedir. Aktivasyon fonksiyonu olarak ReLU, sigmoid veya benzeri doğrusal olmayan fonksiyonlar kullanılabilir [9]. MLP, çalışmaya derin öğrenme yaklaşımının temsilcisi olarak dahil edilmiş; doğrusal olmayan dönüşümleri katmanlı yapısı sayesinde modelleyebilmesi nedeniyle ağaç tabanlı yöntemlerle karşılaştırılabilir bir alternatif olarak değerlendirilmiştir.

3. BULGULAR VE TARTIŞMA (FINDINGS AND DISCUSSION)

Bu çalışmada, havayolu yolcu memnuniyetinin sınıflandırılması amacıyla sekiz farklı makine öğrenmesi modeli ele alınmış ve bunların performansları karşılaştırmalı olarak incelenmiştir. Değerlendirilen modeller k-En Yakın Komşu (k-Nearest Neighbors, kNN), Naive Bayes, Lineer Destek Vektör Makineleri (LSVM), RBF çekirdekli Destek Vektör Makineleri (RBF SVM), Lojistik Regresyon (Logistic Regression), Rastgele Orman (Random Forest), Çok Katmanlı Algılayıcı (Multi-Layer Perceptron, MLP) ve XGBoost algoritmalarıdır. Modellerin birbirleriyle adil biçimde karşılaştırılabilmesi için tümüne aynı ön işleme adımları uygulanmıştır; sayısal değişkenler ölçeklendirilmiş, kategorik değişkenler ise sayısal forma dönüştürülmüştür.

3.1. Beş Katlı Katmanlı Çapraz Doğrulama (5-Fold Stratified Cross Validation)

Model performanslarını tek bir veri bölünmesine bağlı kalmadan ölçebilmek için 5 katlı katmanlı çapraz doğrulama tercih edilmiştir. Bu yöntemde eğitim verisi beş eşit parçaya ayrılır; her seferinde dört parça eğitim, bir parça doğrulama amacıyla kullanılır ve döngü beş kez tekrarlanır. Katmanlı yapı sayesinde hedef sınıfların oranı her foldda korunmuş, böylece veri bölünmesinden kaynaklanabilecek yanıltıcı sonuçların önüne geçilmiştir. Her model için elde edilen beş sonucun ortalaması alınarak genel bir performans değerlendirmesi yapılmıştır. Kaggle'da eğitim ve test verilerinin ayrı dosyalar halinde sunulması ise nihai test setinin yalnızca model seçimi tamamlandıktan sonra kullanılmasına imkân tanımış ve değerlendirme sürecinin bütünlüğünü korumuştur.

3.2. Performans Metrikleri (Performance Metrics)

Bir makine öğrenmesi modelinin başarısı, yalnızca eğitilmesiyle değil ürettiği sonuçların ne kadar doğru ve güvenilir olduğunun ölçülmesiyle değerlendirilir. Bu çalışmada havayolu yolcu memnuniyeti ikili sınıflandırma problemi olarak ele alındığından, modellerin değerlendirilmesinde doğruluk (accuracy), kesinlik (precision), duyarlılık (recall), F1 skoru, özgüllük (specificity) ve Matthews Korelasyon Katsayısı (MCC) kullanılmıştır.

Hedef değişken olan *satisfaction* sütunundaki sınıflar; "neutral or dissatisfied" için 0, "satisfied" için 1 olacak biçimde kodlanmıştır. Buna göre pozitif sınıf memnun yolcuları, negatif sınıf ise memnun olmayan veya nötr yolcuları temsil etmektedir. Performans metriklerinin hesaplanmasında doğru pozitif (TP), doğru negatif (TN), yanlış pozitif (FP) ve yanlış negatif (FN) değerlerinden yararlanılmıştır.

Doğruluk (Accuracy) modelin tüm örnekler arasında kaç tanesini doğru sınıflandırdığını gösterir:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Genel başarımlar hakkında hızlı bir fikir vermekle birlikte sınıf dağılımının dengesiz olduğu durumlarda tek başına yanıltıcı olabilir.

Keskinlik (Precision) modelin pozitif olarak tahmin ettiği örneklerin ne kadarının gerçekten pozitif olduğunu gösterir:

$$Precision = \frac{TP}{TP + FP}$$

Bu çalışmada precision, "memnun" olarak sınıflandırılan yolcuların ne kadarının gerçekten memnun olduğunu ifade etmektedir. Yanlış pozitiflerin maliyetli olduğu senaryolarda öne çıkan bir metriktir.

Duyarlılık (Recall) gerçek pozitif örneklerin ne kadarının model tarafından doğru yakalandığını gösterir:

$$Recall = \frac{TP}{TP + FN}$$

Recall, gerçekte memnun olan yolcuların modelin ne kadarını yakalayabildiğini ölçer. Gözden kaçan pozitiflerin maliyetli olduğu durumlarda kritik hale gelir.

F1 skoru (F1-Score) precision ve recall değerlerinin harmonik ortalamasıdır:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Precision ve recall arasında denge kurulmak istendiğinde yararlı bir metriktir; sınıf dağılımının tam dengeli olmadığı veri kümelerinde model performansını daha dengeli biçimde yansıtır.

Özgüllük (Specificity) modelin negatif sınıfı ne kadar doğru ayırt ettiğini gösterir:

$$Specificity = \frac{TN}{TN + FP}$$

Recall pozitif sınıfa odaklanırken specificity negatif sınıfa odaklanır. Bu çalışmada specificity, modelin memnun olmayan veya nötr yolcuları ne kadar doğru ayırt edebildiğini ölçmektedir.

Matthews Korelasyon Katsayısı (MCC), sınıflandırma problemleri için dengeli ve güvenilir bir performans ölçütüdür ve özellikle sınıf dağılımının tam dengeli olmadığı durumlarda modelin genel başarımlarını sağlıklı biçimde değerlendirmeye yardımcı olur:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

MCC değeri -1 ile $+1$ arasında değişir. $+1$ mükemmel sınıflandırmayı, 0 rastgele tahmini, -1 ise tamamen ters sınıflandırmayı ifade etmektedir. Bu özellikleriyle MCC, modelin sınıflar arasındaki ayrım gücünü özetleyen güçlü bir ölçüt olarak öne çıkmaktadır.

Tüm metrikler her model için çapraz doğrulama sürecinde ayrı ayrı hesaplanmış; hem fold bazlı sonuçlar hem de genel ortalamalar raporlanmıştır. Bu sayede modellerin tek bir veri bölünmesindeki değil, farklı alt kümeler üzerindeki tutarlılığı da değerlendirilmiştir.

3.3. Deneysel Sonuçlar (Experimental Results)

Bu bölümde sekiz farklı makine öğrenmesi modelinin 5 katlı katmanlı çapraz doğrulama sürecinde elde ettiği fold bazlı sonuçlar sunulmakta ve her model için bulgular değerlendirilmektedir. Bölümün sonunda tüm modellerin ortalama performans değerlerini içeren özet bir karşılaştırma tablosuna ve bağımsız test kümesi sonuçlarına yer verilmektedir.

kNN modeline ilişkin fold bazlı sonuçlar Tablo 4'te sunulmaktadır.

Tablo 4. kNN modeli fold bazlı performans sonuçları

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.9249	0.9421	0.8807	0.9104	0.9586	0.8473
2	0.9266	0.9457	0.8813	0.9123	0.9613	0.8509
3	0.9294	0.9456	0.8882	0.9160	0.9609	0.8565
4	0.9290	0.9439	0.8891	0.9157	0.9596	0.8556
5	0.9252	0.9404	0.8833	0.9110	0.95720	0.8478

kNN, beş fold boyunca birbirine çok yakın sonuçlar üreterek istikrarlı bir performans sergilemiştir. Ortalama doğruluk %92,70, MCC ise 0,8516 olarak elde edilmiştir. Kesinlik değerinin (0,9435) duyarlılık değerinin (0,8845) üzerinde kalması dikkat çekmektedir; model pozitif tahminlerinde güvenilir olmakla birlikte memnun yolcuların bir kısmını gözden kaçırmaktadır. Özgüllüğün 0,9595 düzeyinde olması ise negatif sınıfın da başarıyla tanındığını göstermektedir.

Naive Bayes modeline ilişkin fold bazlı sonuçlar Tablo 5'te sunulmaktadır.

Tablo 5. Naive Bayes modeli fold bazlı performans sonuçları

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.8489	0.8369	0.8091	0.8228	0.8794	0.6915
2	0.8462	0.8299	0.8112	0.8205	0.8729	0.6860
3	0.85054	0.8320	0.8209	0.8264	0.8732	0.6952
4	0.8525	0.8316	0.8271	0.8294	0.8719	0.6995
5	0.84394	0.8271	0.8090	0.8179	0.8707	0.6815

Naive Bayes, sekiz model arasında en düşük performansı veren yöntem olmuştur. Ortalama doğruluk %84,84, MCC ise 0,6908 ile diğer modellerin belirgin biçimde gerisinde kalmıştır. Bu durumun temel nedeni, Naive Bayes'in koşullu bağımsızlık varsayımının veri setinde sağlanamamasıdır; hizmet kalitesi değerlendirmeleri gibi değişkenler arasındaki güçlü korelasyonlar bu varsayımı doğrudan ihlal etmektedir.

Yine de fold sonuçları kendi içinde tutarlı seyretmiş, belirgin bir dalgalanma gözlemlenmemiştir.

Lojistik Regresyon modeline ilişkin fold bazlı sonuçlar Tablo 6'da sunulmaktadır.

Tablo 6. *Lojistik Regresyon modeli fold bazlı performans sonuçları*

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.8776	0.8786	0.8325	0.8549	0.9120	0.7500
2	0.8718	0.8651	0.8341	0.8493	0.9006	0.7381
3	0.8769	0.8689	0.8432	0.8558	0.9027	0.7487
4	0.8762	0.8706	0.8390	0.8545	0.9046	0.7472
5	0.8736	0.8709	0.8316	0.8508	0.9057	0.7419

Lojistik Regresyon, doğrusal modeller arasında sağlam bir temel başarımlar göstermiştir. Ortalama doğruluk %87,52, MCC ise 0,7452 olarak hesaplanmıştır. Fold sonuçları arasındaki fark oldukça küçük kalmış; bu da modelin veri bölünmesinden bağımsız biçimde kararlı çalıştığını ortaya koymaktadır. Ancak doğrusal karar sınırına dayanan bu yapının veri setindeki karmaşık ilişkileri tam olarak yakalayamadığı görülmektedir.

LSVM modeline ilişkin fold bazlı sonuçlar Tablo 7'de sunulmaktadır.

Tablo 7. *LSVM modeli fold bazlı performans sonuçları*

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.8771	0.8790	0.8309	0.8543	0.9125	0.7491
2	0.8702	0.8654	0.8294	0.8470	0.9013	0.7348
3	0.8766	0.8700	0.84087	0.8552	0.9040	0.7481
4	0.8757	0.8703	0.8390	0.8538	0.9045	0.7461
5	0.8724	0.8701	0.8293	0.8492	0.9053	0.7393

LSVM, Lojistik Regresyon ile neredeyse özdeş bir performans tablosu ortaya koymuştur. Ortalama doğruluk %87,44, MCC ise 0,7435 olup iki model arasındaki fark ihmal edilebilir düzeydedir. Bu benzerlik, her iki yöntemin de doğrusal karar sınırı mantığıyla çalışmasından kaynaklanmaktadır.

RBF SVM modeline ilişkin fold bazlı sonuçlar Tablo 8'de sunulmaktadır.

Tablo 8. *RBF SVM modeli fold bazlı performans sonuçları*

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.9531	0.9595	0.9310	0.9450	0.9699	0.9044
2	0.9516	0.9562	0.9309	0.9434	0.9674	0.9014
3	0.9544	0.9579	0.9359	0.9468	0.9686	0.9071
4	0.9521	0.9564	0.9320	0.9440	0.9675	0.9024
5	0.9514	0.9572	0.9294	0.9431	0.9682	0.9010

RBFSVM, doğrusal modellere kıyasla çok daha yüksek bir başarımla sergilemiş ve MCC değerini 0,90 eşiğinin üzerine taşımıştır. Ortalama doğruluk %95,25, F1 skoru ise 0,9445 olarak elde edilmiştir. Çekirdek dönüşümü sayesinde veri setindeki doğrusal olmayan ilişkilerin başarıyla yakalandığı görülmektedir. Beş fold boyunca sonuçlar birbirine çok yakın seyretmiş; bu da modelin yüksek kararlılığa sahip olduğunu göstermektedir.

Random Forest modeline ilişkin fold bazlı sonuçlar Tablo 9'da sunulmaktadır.

Tablo 9. Random Forest modeli fold bazlı performans sonuçları

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.9631	0.9744	0.9396	0.9567	0.9811	0.9251
2	0.9617	0.9729	0.9378	0.9550	0.9800	0.9222
3	0.9643	0.9719	0.9449	0.95822	0.9791	0.9273
4	0.9625	0.9702	0.9424	0.9561	0.9778	0.9236
5	0.9614	0.9724	0.9375	0.95456	0.9796	0.9214

Random Forest, çalışmanın en yüksek başarımlarını gösteren modellerden biri olmuştur. Kesinlik (0,9704) ve özgüllük (0,9796) değerleri tüm modeller içinde en yüksek düzeye ulaşmıştır. Bu durum, modelin hem memnun yolcuları doğru etiketlemede hem de memnun olmayanları ayırt etmede aynı anda güçlü performans sergilediğini göstermektedir. Topluluk öğrenme yapısı sayesinde fold sonuçları arasındaki fark çok küçük kalmış; bu da modelin veri bölünmesinden bağımsız biçimde kararlı çalıştığını ortaya koymaktadır.

MLP modeline ilişkin fold bazlı sonuçlar Tablo 10'da sunulmaktadır.

Tablo 10. MLP modeli fold bazlı performans sonuçları

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
1	0.9572	0.9600	0.9405	0.9501	0.9700	0.9128
2	0.9557	0.9581	0.9389	0.9484	0.9686	0.9098
3	0.9594	0.9576	0.9483	0.9529	0.9679	0.9172
4	0.9597	0.9636	0.9429	0.9530	0.9727	0.9178
5	0.9531	0.9401	0.9526	0.9463	0.9535	0.9048

MLP, RBF SVM ile Random Forest arasında konumlanarak güçlü bir başarımla sergilemiştir. Ortalama doğruluk %95,70, duyarlılık ise 0,9446 ile sekiz model arasında en yüksek ikinci değere ulaşmıştır. Bu, yapay sinir ağı yapısının memnun yolcuları tanıma konusunda özellikle etkili olduğunu göstermektedir. 5. foldda özgüllük değerinin (0,9535) diğer foldlara kıyasla belirgin biçimde düşmesi ise modelin söz konusu veri bölünmesinde negatif sınıfı ayırt etmekte görece zorlandığını ortaya koymaktadır.

XGBoost modeline ilişkin fold bazlı sonuçlar Tablo 11'de sunulmaktadır.

Tablo 11. XGBoost modeli fold bazlı performans sonuçları

Fold	Accuracy	Precision	Recall	F1	Specificity	MCC
------	----------	-----------	--------	----	-------------	-----

1	0.9629	0.9704	0.9430	0.9565	0.9780	0.9244
2	0.9617	0.9702	0.9405	0.9551	0.9779	0.9221
3	0.9648	0.9722	0.9459	0.9589	0.9793	0.9284
4	0.9643	0.9718	0.9450	0.9582	0.9790	0.9273
5	0.9606	0.9667	0.9416	0.9540	0.9752	0.9198

XGBoost, Random Forest ile neredeyse eşdeğer bir performans tablosu ortaya koymuş ve doğruluk bakımından (%96,29) çalışmanın en yüksek değerine ulaşmıştır. Duyarlılık (0,9432) açısından Random Forest'ı hafif geride bırakırken kesinlik ve özgüllük değerlerinde iki model arasındaki fark ihmal edilebilir düzeydedir. Kademeli hata düzeltme mekanizmasının veri setindeki karmaşık örüntüleri yakalamada etkili olduğu görülmektedir.

Tüm modellerin ortalama performans değerleri Tablo 12'de doğruluk değerine göre büyükten küçüğe sıralanmış biçimde sunulmaktadır.

Tablo 12. Tüm modellerin ortalama performans karşılaştırması

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
XGBoost	0.9629	0.9703	0.9432	0.9565	0.9779	0.9244
Random Forest	0.9626	0.9724	0.9404	0.9561	0.9796	0.9239
MLP	0.9570	0.9559	0.9446	0.9501	0.9666	0.9125
RBF SVM	0.9525	0.9574	0.9319	0.9445	0.9683	0.9033
kNN	0.9270	0.9435	0.8845	0.9131	0.9595	0.8516
Lojistik Regresyon	0.8752	0.8708	0.8361	0.8531	0.9051	0.7452
LSVM	0.8744	0.8710	0.8337	0.8519	0.9055	0.7435
Naive Bayes	0.8484	0.8315	0.8155	0.8234	0.8736	0.6908

Tablo 12 incelendiğinde, modellerin başarımının kullanılan algoritma türüyle doğrudan ilişkili olduğu görülmektedir. Doğrusal karar sınırına dayanan Naive Bayes, LSVM ve Lojistik Regresyon, %84-88 doğruluk aralığında kalarak diğer gruplardan belirgin biçimde geride kalmıştır. Bu durum, havayolu yolcu memnuniyeti veri setinin doğrusal olarak ayrılabilir bir yapıya sahip olduğuna işaret etmektedir. Hizmet kalitesi değerlendirmeleri, seyahat türü, müşteri tipi ve gecikme bilgileri arasındaki karmaşık etkileşimler, doğrusal yöntemlerin sınırlılıklarını açıkça ortaya koymaktadır.


kNN, bu grubun üzerine çıkarak %92,70 doğruluk ve 0,8516 MCC ile belirgin bir sıçrama gerçekleştirmiştir. Parametrik olmayan yapısı sayesinde doğrusal olmayan örüntüleri yakalayabilen kNN, özellikle kesinlik değeriyle (0,9435) öne çıkmaktadır. Bununla birlikte duyarlılık değerinin (0,8845) kesinliğin gerisinde kalması, modelin memnun yolcuların bir kısmını gözden kaçırdığını ve yüksek boyutlu uzaklık hesaplamalarına dayalı yapısının veri setinin tüm nüanslarını yakalamada yetersiz kaldığını göstermektedir.

Çekirdek tabanlı RBF SVM ve sinir ağı tabanlı MLP, kNN'e kıyasla kayda değer bir artış sergileyerek %95'in üzerinde doğruluk ve 0,90'ı aşan MCC değerlerine ulaşmıştır. RBF SVM'in çekirdek dönüşümü, MLP'nin ise gizli katmanları sayesinde doğrusal olmayan ilişkileri modelleyebildiği ve bu sayede veri yapısına daha uygun karar sınırları oluşturduğu değerlendirilmektedir. İki model arasında doğruluk ve F1

skoru bakımından yakın bir rekabet gözlemlenmiş; MLP duyarlılık bakımından öne çıkarken RBF SVM kesinlik değerinde hafif bir üstünlük sağlamıştır.

Çalışmanın en yüksek başarımı ise ağaç tabanlı topluluk yöntemleri olan Random Forest ve XGBoost tarafından paylaşılmıştır. Her iki model de %96'nın üzerinde doğruluk, 0,95'i aşan F1 skoru ve 0,92'nin üzerinde MCC değeriyle tüm metrikler bakımından tutarlı bir üstünlük sergilemiştir. Random Forest kesinlik ve özgüllük değerleriyle öne çıkarken XGBoost duyarlılık ve MCC açısından hafif bir avantaj taşımaktadır. Bu yakın rekabet, her iki modelin de havayolu yolcu memnuniyeti sınıflandırması için güçlü alternatifler olduğunu ortaya koymaktadır.

Fold bazlı değerlendirmede tüm modeller yüksek istikrar göstermiş; doğruluk ve F1 gibi temel metriklerdeki fold-içi dalgalanmalar oldukça sınırlı kalmıştır. Bu durum, sonuçların veri bölünmesinden bağımsız biçimde tekrarlanabilir ve güvenilir olduğunu, 5 katlı katmanlı çapraz doğrulamanın da model karşılaştırması için sağlam bir değerlendirme çerçevesi sunduğunu doğrulamaktadır.



Şekil 1. Modellerin genel performans karşılaştırması

Şekil 1 incelendiğinde, XGBoost ve Random Forest'ın her üç metrikte de tutarlı biçimde en yüksek değerlere ulaştığı açıkça görülmektedir. Doğrusal modeller olan Lojistik Regresyon, LSVM ve Naive Bayes ise diğer gruplardan belirgin biçimde ayrılarak daha düşük bir bant oluşturmaktadır. Özellikle MCC değerlerindeki bu ayrışma, doğrusal yöntemlerin veri setindeki karmaşık ilişkileri yakalamada yetersiz kaldığını görsel olarak da ortaya koymaktadır.

Modellerin bağımsız test kümesindeki performansları Tablo 13'te sunulmaktadır.

Tablo 13. Tüm modellerin bağımsız test kümesi performans sonuçları

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
-------	----------	-----------	--------	----	-------------	-----

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
Random Forest	0.9634	0.9729	0.9430	0.9577	0.9794	0.9259
XGBoost	0.9634	0.9716	0.9443	0.9578	0.9784	0.9258
MLP	0.9597	0.9638	0.9435	0.9536	0.9723	0.9181
RBF SVM	0.9542	0.9584	0.9363	0.9472	0.9682	0.9070
kNN	0.9292	0.9447	0.8910	0.9171	0.9592	0.8566
Lojistik Regresyon	0.8718	0.8694	0.8333	0.8509	0.9020	0.7391
LSVM	0.8708	0.8694	0.8304	0.8494	0.9024	0.7369
Naive Bayes	0.8441	0.8292	0.8122	0.8206	0.8691	0.6829

Bağımsız test kümesi sonuçları, çapraz doğrulama aşamasında gözlemlenen tabloyla büyük ölçüde örtüşmektedir. Model sıralaması neredeyse aynı kalmış, performans değerleri de birbirine yakın seyretmiştir. Bu durum, modellerin eğitim verisine aşırı uyum sağlamadığını ve görülmemiş veriye başarıyla genelleme yapabildiğini göstermektedir.

Random Forest ve XGBoost, bağımsız test kümesinde de zirveyi 0,9634 doğrulukla paylaşmıştır. İki model arasındaki çapraz doğrulamada zaten küçük olan fark, bu aşamada tamamen ortadan kalkmıştır. MLP ise 0,9597 doğrulukla bu iki modelin hemen gerisinde yer almış ve güçlü genelleme kapasitesini kanıtlamıştır. Doğrusal modeller %87-88 doğruluk bandında kalmaya devam etmiş; Naive Bayes ise yine en düşük başarıyı göstermiştir. Genel olarak bu sonuçlar, çapraz doğrulamanın model karşılaştırması için güvenilir bir çerçeve sunduğunu ve nihai test sonuçlarıyla tutarlı bir tablo ortaya koyduğunu doğrulamaktadır.

3.4. SHAP Tabanlı Öznitelik Seçimi Sonuçları (SHAP-Based Feature Selection Results)

Bölüm 3.3'te sunulan baseline sonuçlar, modellerin tüm 22 öznitelik kullanılarak elde ettiği başarıyı yansıtmaktadır. Bu bölümde ise SHAP tabanlı öznitelik seçimi sonrasında 14 öznitelikle yeniden eğitilen modellerin performansları ele alınmakta ve baseline ile karşılaştırılmaktadır. Bu sayede öznitelik sayısının yaklaşık üçte bir oranında azaltılmasının model başarıyı üzerindeki etkisi değerlendirilebilmektedir.

SHAP seçimi sonrasında elde edilen ortalama çapraz doğrulama sonuçları Tablo 14'te sunulmaktadır.

Tablo 14. SHAP seçimi sonrası modellerin ortalama 5-katlı çapraz doğrulama performansı

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
XGBoost	0,9617	0,9710	0,9397	0,9551	0,9785	0,9221
MLP	0,9574	0,9620	0,9387	0,9502	0,9716	0,9131
Random Forest	0,9568	0,9620	0,9373	0,9495	0,9717	0,9120
RBF SVM	0,9547	0,9621	0,9321	0,9468	0,9719	0,9077
kNN	0,9380	0,9568	0,8974	0,9261	0,9690	0,8741

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
Lojistik Regresyon	0,8733	0,8676	0,8350	0,8510	0,9026	0,7412
LSVM	0,8726	0,8679	0,8328	0,8500	0,9031	0,7399
Naive Bayes	0,8555	0,8408	0,8223	0,8314	0,8809	0,7052

Tablo 14'teki sonuçlar Bölüm 3.3'teki baseline değerleriyle (Tablo 12) karşılaştırıldığında, SHAP tabanlı öznelik seçiminin model türüne göre farklı etkiler ürettiği dikkat çekmektedir. En belirgin iyileşme **kNN** modelinde gözlemlenmiştir; doğruluk değeri %92,70'ten %93,80'e yükselmiş, MCC ise 0,8516'dan 0,8741'e çıkmıştır. Bu artış, uzaklık tabanlı yöntemlerin yüksek boyutlu uzaylarda yaşadığı performans kayıplarına ("curse of dimensionality") karşı duyarlı olduğunu, dolayısıyla zayıf bilgi taşıyan özneliklerin elenmesinin bu modele doğrudan fayda sağladığını ortaya koymaktadır.

Naive Bayes de SHAP seçiminden anlamlı biçimde fayda görmüş; doğruluk %84,84'ten %85,55'e, MCC ise 0,6908'den 0,7052'ye yükselmiştir. Bu iyileşme, Naive Bayes'in temelindeki koşullu bağımsızlık varsayımıyla doğrudan ilişkilidir: birbirleriyle yüksek korelasyona sahip ve zayıf katkı sağlayan özneliklerin elenmesi, varsayımın ihlal edildiği durumların azalmasına yol açmıştır. RBF SVM modelinde de küçük bir iyileşme gözlemlenmiş (doğrulukta yaklaşık 0,002 puan artış); bu, seçim sürecinin kernel tabanlı yöntemlerde de etkili olabildiğine işaret etmektedir.

Buna karşılık **XGBoost ve Random Forest** modellerinde küçük düşüşler kaydedilmiştir. XGBoost'un doğruluğu yalnızca 0,12 puan düşmüş (0,9629 → 0,9617), Random Forest ise daha belirgin bir düşüş yaşamıştır (0,9626 → 0,9568). Bu sonuç, ağaç tabanlı topluluk yöntemlerinin gürültülü veya zayıf özneliklere karşı doğal olarak dirençli olduğunu, dolayısıyla elenen özneliklerin az da olsa modele katkı sağladığını göstermektedir. Yine de bu düşüşlerin ihmal edilebilir düzeyde olması, **öznelik sayısının %36 oranında azaltılmasına rağmen başarımın korunabildiğini** ortaya koymaktadır. MLP ise neredeyse hiç değişmemiş (0,9570 → 0,9574); bu da yapay sinir ağlarının dahili olarak öznelik ağırlıklarını öğrenebilmesi sayesinde ekstra öznelik eleminin model üzerinde belirleyici bir etki yaratmadığını göstermektedir.

Doğrusal modeller olan Lojistik Regresyon ve LSVM'de küçük düşüşler gözlemlenmiş, ancak bu düşüşler 0,002 mertebesinde kalmıştır. Bu modeller zaten doğrusal karar sınırlarına dayandığı için hem baseline hem de SHAP seçimi sonrasında benzer bir performans tavanına ulaşmıştır.

SHAP seçimi sonrası bağımsız test kümesi sonuçları Tablo 15'te sunulmaktadır.

Tablo 15. SHAP seçimi sonrası modellerin bağımsız test kümesi performansı

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
XGBoost	0,9619	0,9711	0,9413	0,9560	0,9780	0,9228
MLP	0,9597	0,9642	0,9433	0,9536	0,9726	0,9182
Random Forest	0,9570	0,9601	0,9412	0,9505	0,9694	0,9127
RBF SVM	0,9550	0,9615	0,9350	0,9481	0,9707	0,9087
kNN	0,9390	0,9540	0,9047	0,9287	0,9659	0,8764
Lojistik Regresyon	0,8692	0,8644	0,8327	0,8482	0,8978	0,7338
LSVM	0,8678	0,8643	0,8291	0,8463	0,8982	0,7310

Model	Accuracy	Precision	Recall	F1	Specificity	MCC
Naive Bayes	0,8512	0,8396	0,8171	0,8282	0,8779	0,6972

Bağımsız test kümesi sonuçları, çapraz doğrulamada gözlemlenen tablonun büyük ölçüde sürdüğünü göstermektedir. XGBoost %96,19 doğrulukla zirvede yer almış; bunu MLP (%95,97) ve Random Forest (%95,70) takip etmiştir. Baseline aşamasında 0,9634 doğrulukla eşit zirveyi paylaşan XGBoost ve Random Forest arasındaki fark, SHAP seçimi sonrası hafifçe XGBoost lehine açılmıştır.

Genel bir değerlendirme yapıldığında, SHAP tabanlı öznetelik seçiminin başlıca üç önemli sonuç ürettiği söylenebilir. Birincisi, öznetelik sayısı 22'den 14'e düşürülmesine karşın en iyi modellerin doğruluk değerlerindeki kayıp 0,01 puanın altında kalmıştır; bu da seçim sürecinin etkili biçimde çalıştığını göstermektedir. İkincisi, kNN ve Naive Bayes gibi öznetelik sayısına duyarlı modeller bu süreçten doğrudan fayda görmüş; bu durum SHAP'ın yalnızca bir önem ölçütü değil, aynı zamanda model karmaşıklığını yönetmeye yardımcı bir araç olduğunu kanıtlamaktadır. Üçüncüsü, çıkarılan değişkenler (cinsiyet, yaş, uçuş mesafesi, gecikme süreleri) ağırlıklı olarak demografik ve operasyonel bilgi taşıırken; korunan değişkenlerin büyük çoğunluğu hizmet kalitesi değerlendirmelerinden oluşmaktadır. Bu bulgu, havayolu yolcu memnuniyetinin temelde **demografik faktörlerden çok hizmet deneyimine bağlı** olduğunu somut biçimde ortaya koymaktadır.

3.5. Literatür Karşılaştırması (Comparison with Literature)

Bu çalışmada elde edilen sonuçların alanyazındaki benzer çalışmalarla karşılaştırılması, modellerin başarımını daha geniş bir bağlamda değerlendirme imkânı sunmaktadır.

Islam ve ark. [2], aynı veri seti üzerinde GridSearch hiperparametre optimizasyonu ve üç farklı öznetelik azaltma tekniğini birleştirerek Random Forest ile %97 doğruluk elde etmiştir. Bu çalışmada ise herhangi bir hiperparametre optimizasyonu uygulanmaksızın varsayılan parametrelerle eğitilen Random Forest, baseline'da %96,34, SHAP seçimi sonrasında ise %95,70 doğruluk göstermiştir. Aradaki yaklaşık 1 puanlık fark, kapsamlı optimizasyon süreçleri uygulanmaksızın da rekabetçi başarımlara ulaşılabilirliğini ve tutarlı bir ön işleme hattının model başarımı üzerinde belirleyici bir rol oynadığını ortaya koymaktadır.

Noviantoro ve Huang [3], on farklı algoritmayı öznetelik seçimi sonrasında karşılaştırmış; Deep Learning %95,42 ve Random Forest %94,41 doğrulukla öne çıkmıştır. Söz konusu çalışmanın **online boarding ve uçuş içi wifi hizmetinin memnuniyette en belirleyici değişkenler olduğu** bulgusu, çalışmamızdaki SHAP sıralamasıyla büyük ölçüde örtüşmektedir; *Inflight wifi service* (%19,37) ve *Online boarding* (%11,21) en yüksek öneme sahip değişkenler olarak öne çıkmıştır. Bu örtüşme, iki farklı yöntemle tutarlı sonuçlara ulaşılabildiğini ve havayolu yolcu memnuniyetinde bu hizmet boyutlarının kararlı biçimde belirleyici olduğunu desteklemektedir.

Jiang ve ark. [4], RF-RFE yöntemiyle 22 öznetelikten 17'sini seçerek Random Forest ile 0,963 doğruluk ve 0,957 F1 skoru elde etmiştir. Bu çalışmada uygulanan SHAP tabanlı seçim ise yalnızca 14 öznetelik kullanarak XGBoost ile bağımsız test kümesinde 0,9619 doğruluk ve 0,9560 F1 skoru üretmiştir. Daha agresif bir öznetelik azaltmasına (22→14 vs 22→17) rağmen elde edilen yakın başarımlar, SHAP'ın model-agnostik yapısı sayesinde RF-RFE gibi sarmalayıcı yaklaşımlarla rekabet edebilir sonuçlar verdiğini göstermektedir.

Hong ve ark. [5] korelasyon analizine dayalı öznetelik seçimi sonrasında Random Forest ile %89,20 doğruluk elde etmiştir. Bu çalışmada ise SHAP seçimi sonrasında dahi Random Forest %95,70 doğrulukla belirgin biçimde daha yüksek bir başarımla sergilemiştir. Aradaki fark, doğrusal ilişkilere dayanan korelasyon analizinin, doğrusal olmayan etkileşimleri yakalamada SHAP'e kıyasla sınırlı kaldığına işaret etmektedir.

Ouf [6], Adam optimizasyonu ile eğitilmiş derin sinir ağı kullanarak %99,3 doğruluk elde etmiş ve bunu literatürdeki en yüksek sonuç olarak bildirmiştir. Bu değer, çalışmamızdaki MLP sonucunun (SHAP sonrası %95,97) belirgin biçimde üzerindedir. Ancak söz konusu çalışmada kapsamlı hiperparametre optimizasyonu

ve özelleştirilmiş bir mimari kullanılmıştır. Bu çalışmanın hedefi ise tek bir modeli uç noktaya taşımak değil; sekiz algoritmayı aynı koşullar altında karşılaştırarak SHAP tabanlı öznitelik seçiminin model başarımına etkisini sistematik biçimde değerlendirmektir.

Mevcut çalışmaların büyük çoğunluğunda öznitelik seçimi ya hiç uygulanmamış ya da geleneksel yöntemlerle (RF-RFE, korelasyon analizi) sınırlı kalmıştır. SHAP ise bu veri seti üzerinde yalnızca açıklanabilirlik amacıyla ele alınmış [10]; bir öznitelik seçim mekanizması olarak doğrudan kullanılmamıştır. Bu yönüyle çalışmamız, SHAP değerlerini havayolu yolcu memnuniyeti tahmini bağlamında öznitelik seçimi için uygulayan ilk çalışmalardan biri olarak literatüre özgün bir katkı sunmaktadır.

4. SONUÇLAR (CONCLUSIONS)

Bu çalışmada, havayolu yolcu memnuniyetinin makine öğrenmesi yöntemleri kullanılarak sınıflandırılması amaçlanmıştır. Bu kapsamda Kaggle platformunda açık erişimli olarak sunulan Airline Passenger Satisfaction veri seti kullanılmış; veri ön işleme aşamasında gereksiz sütunlar çıkarılmış, eksik değerler medyan ile doldurulmuş, kategorik değişkenler One-Hot Encoding ile sayısallaştırılmış ve sayısal değişkenler StandardScaler ile ölçeklendirilmiştir. Ardından kNN, Naive Bayes, LSVM, RBF SVM, Lojistik Regresyon, Random Forest, XGBoost ve MLP olmak üzere sekiz farklı sınıflandırma algoritması aynı deneysel kurulum altında karşılaştırılmıştır.

Elde edilen sonuçlar, havayolu yolcu memnuniyeti probleminin doğrusal olmayan ilişkiler içerdiğini ve bu nedenle ağaç tabanlı topluluk öğrenme yöntemleri ile esnek doğrusal olmayan modellerin daha başarılı performans gösterdiğini ortaya koymuştur. Beş katlı katmanlı çapraz doğrulama sonuçlarına göre en yüksek doğruluk ve F1 skoru değerleri XGBoost ve Random Forest modelleri tarafından elde edilmiştir. XGBoost doğruluk, F1 skoru ve MCC bakımından en başarılı yöntem olarak öne çıkarken Random Forest da çok yakın performans sergileyerek güçlü bir alternatif olduğunu göstermiştir. MLP ve RBF SVM modelleri de yüksek başarı göstermiş; bu durum, veri setindeki karmaşık örüntülerin doğrusal olmayan modeller tarafından daha etkili biçimde öğrenilebildiğini desteklemiştir. Buna karşılık Lojistik Regresyon ve LSVM gibi doğrusal modeller daha sınırlı başarı üretmiş; Naive Bayes ise koşullu bağımsızlık varsayımının veriye uygun olmaması nedeniyle en düşük performansı göstermiştir. Özellikle hizmet kalitesine ilişkin değişkenlerin birbirleriyle ilişkili yapıda olması, Naive Bayes'in görece düşük performansının başlıca nedeni olarak değerlendirilebilir.

Çalışmanın özgün katkısı olarak, literatürde bu veri seti üzerinde yalnızca açıklanabilirlik amacıyla kullanılan SHAP değerleri, bir öznitelik seçim mekanizması olarak uygulanmıştır. XGBoost ve Random Forest modellerinden elde edilen normalize SHAP skorlarının birleştirilmesiyle 22 öznitelikten 14'ü seçilmiş ve modeller bu alt küme ile yeniden eğitilmiştir. Sonuçlar, öznitelik sayısı yaklaşık üçte bir oranında azaltılmasına karşın en başarılı modellerin doğruluk değerlerindeki kaybın 0,01 puanın altında kaldığını göstermiştir. Üstelik kNN ve Naive Bayes gibi öznitelik sayısına duyarlı modeller bu süreçten anlamlı biçimde fayda görmüştür. Çıkarılan değişkenlerin ağırlıklı olarak demografik ve operasyonel bilgi taşıması; korunan değişkenlerin ise hizmet kalitesi değerlendirmelerinden oluşması, havayolu yolcu memnuniyetinin temelde **hizmet deneyimine bağlı** olduğunu somut biçimde ortaya koymaktadır.

Genel olarak değerlendirildiğinde, bu çalışma makine öğrenmesi algoritmalarının havayolu yolcu memnuniyetini tahmin etmede etkili ve uygulanabilir sonuçlar üretebildiğini göstermektedir. XGBoost ve Random Forest modellerinin yüksek doğruluk, dengeli F1 skoru ve güçlü MCC değerleri üretmesi, bu yöntemlerin karar destek sistemleri, müşteri memnuniyeti analizi ve hizmet kalitesi iyileştirme süreçlerinde kullanılabileceğini ortaya koymaktadır. Ayrıca SHAP tabanlı öznitelik seçiminin bu bağlamda ilk kez uygulanması, model-agnostik ve oyun teorisine dayalı bir öznitelik seçim çerçevesinin pratik kullanımına ilişkin literatüre özgün bir katkı sunmuştur.

Gelecek çalışmalarda, modellerin hiperparametre optimizasyonu daha ayrıntılı biçimde ele alınabilir ve farklı SHAP eşik değerlerinin (örneğin %85 veya %95) öznitelik seçim sürecine etkisi incelenebilir. Bunun yanı sıra sınıf dengesizliği, olasılık kalibrasyonu, öznitelik mühendisliği ve derin öğrenme tabanlı gelişmiş mimariler üzerinde yapılacak ek çalışmaların, model performansını daha da ileri taşıyabileceği

düşünülmektedir.

KAYNAKLAR (REFERENCES)

- [1] International Air Transport Association (IATA), "Global Passenger Survey (GPS)", <https://www.iata.org/en/publications/manuals/global-passenger-survey/>, Erişim: 21 Nisan 2026.
- [2] Islam, F. ve diğerleri, "An Investigation of Hyperparameters Optimization and Feature Reduction Techniques: Predicting Airline Passenger Satisfaction Using Machine Learning Models", 26th International Conference on Computer and Information Technology (ICCIT), IEEE, 2023.
- [3] Noviantoro, T., Huang, J.-P., "Investigating Airline Passenger Satisfaction: Data Mining Method", Research in Transportation Business & Management, Cilt 43, 100726, 2022.
- [4] Jiang, X., Zhang, Y., Li, Y., Zhang, B., "Forecast and Analysis of Aircraft Passenger Satisfaction Based on RF-RFE-LR Model", Scientific Reports, Cilt 12, 11174, 2022.
- [5] Hong, A.C.Y., Khaw, K.W., Chew, X., Yeong, W.C., "Prediction of US Airline Passenger Satisfaction Using Machine Learning Algorithms", Data Analytics and Applied Mathematics, Cilt 4, No 1, 7-22, 2023.
- [6] Ouf, S., "An Optimized Deep Learning Approach for Improving Airline Services", Computers, Materials & Continua, Cilt 75, No 1, 1213-1233, 2023.
- [7] Mahal, T.J., "Airline Passenger Satisfaction", Kaggle, <https://www.kaggle.com/datasets/teejmahal20/airline-passenger-satisfaction>, 2020, Erişim: 15 Nisan 2026.
- [8] Gök, M., "Makine Öğrenmesi Algoritmaları", Nobel Yayın, Ankara, 2024.
- [9] Géron, A., "Hands-On Machine Learning", O'Reilly Media, Sebastopol, CA, 2019.
- [10] Lundberg, S.M., Lee, S.-I., "A Unified Approach to Interpreting Model Predictions", Advances in Neural Information Processing Systems (NeurIPS), Cilt 30, 4765-4774, 2017.